面向持续学习智能体的记忆护栏

MemoryGuard

让 API 文档更新成为可检查、可追溯的记忆变化。

本次运行	已保存证据
6 条合成任务流，216 次任务执行	配置、任务流、独立答案、逐次原始请求与响应
治理记忆成功：32/36（88.9%）	普通记忆成功：21/36（58.3%）
治理旧任务退化：1/17（5.9%）	普通记忆旧任务退化：5/10（50.0%）
真实模型请求：216；规划错误：7	固定 Qwen3-0.6B Q8_0，CPU 本地推理

作品面向持续接收项目文档与纠错反馈的开发助手。模型权重保持固定，通过外部记忆学习新 API；记忆治理处理范围、重复、冲突和授权替代。工具执行由独立本地模拟器评分。

本报告只解释本次开发者可见的合成对照结果；不将历史规则回归、开发过程使用 AI 或未运行接口计入生成模型效果。

2026 年 10 月 28 日 · 匿名评审材料

场景与研究问题

开发助手常常需要记住一个项目多个版本的 API。新文档并不总是替代旧文档：仍在维护的 v1 客户端继续使用 v1 路径，新客户端则需要 v2 的认证字段。重复消息、未经确认的笔记和后续纠错会同时进入记忆。

研究问题是：学习新知识后，助手能否提高新任务表现，同时保留答案仍然有效的旧任务？这里的持续学习采用固定权重下的非参数外部记忆适应，工程未实现模型参数训练。

四类连续场景

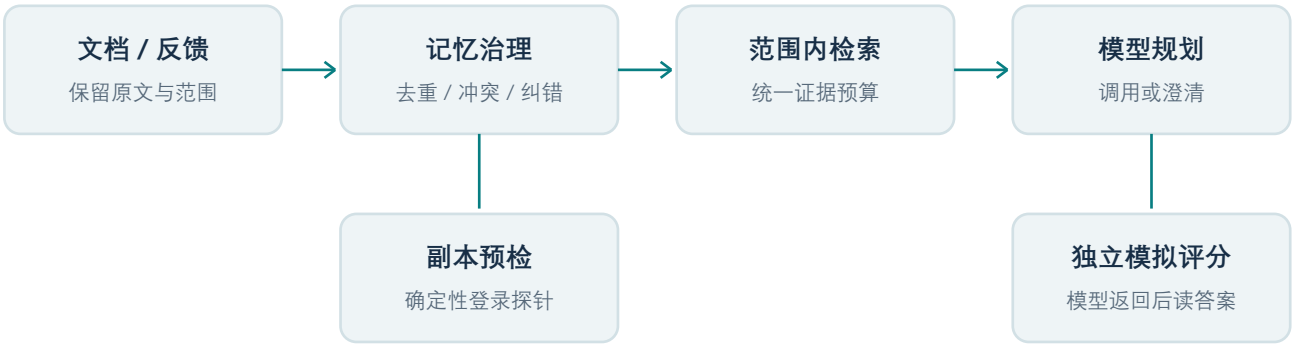
场景	观察重点
版本并存	学习 v2 后仍可完成合法 v1 任务；普通基线也获得项目、版本过滤。
正常知识学习	v2 证据到达前应澄清，到达后能生成适用调用。
重复信息干扰	同一 v1 属性的重复观察会否挤出另一个必需属性。
冲突与授权纠错	证据矛盾时合理澄清，确认替代后恢复调用。

负影响的判定

仅当同一旧任务在前次检查点成功、前后均可回答、公开任务哈希及评分答案哈希均相同时，才把它纳入退化率分母。更新后失败计为退化。合法的 API 变更和真实冲突下的澄清，不被自动判为遗忘。分母为 0 时报告不适用。

目标使用者是本机操作的开发者。当天范围限定一个助手、一个固定模型、一类登录工具与上述四类记忆场景；多租户、模型训练和真实业务 API 执行不在本次交付范围。

实现架构与信息边界



上图实线表示本次任务执行主链路。副本预检与独立评分分别服务更新决策和实验判定，二者不共享隐藏答案。

层次	实现与作用
持久化与审计	SQLite 追加事件、事实、证据、关系及决策，保留检查点前缀。
提取与记忆治理	规则提取带原文跨度的 API 属性；范围隔离、重复证据关联、冲突保留、授权纠错。
检索与预算	按项目、版本及所需属性检索；治理上下文每个事实保留一份代表证据，审计库保留完整证据。
真实模型规划	ChatPlanner 向本地 chat-completions 服务发送任务与证据，生成结构化调用或澄清。
独立评分	mock_api_call 在模型返回后检查项目、版本、路径与认证字段；不发业务网络请求。

模型只能看到白名单内的公开任务字段和方法提供的上下文，task_id 等管理字段不进入模型输入；它不接收未来事件、评分标签、模拟工具规格或评分结果回写。探针前后记忆状态哈希必须一致，避免评测任务本身成为额外学习。

工作台仍使用确定性规划器；真实模型入口位于 Python SDK、CLI 和 day1 评测。此次接入没有把工作台预检改造成真实模型全能力预检。

记忆更新、冲突与可恢复性

每条输入包含项目、版本、来源和原文。规则提取候选值并检查它能否在原文证据跨度中逐字找到；含条件、否定或缺失范围的输入保留待复核，避免把含糊文字直接转成明确事实。

机制	实现结果
版本隔离	不同项目、版本或不重叠有效区间的事实可并存，任务只读取适用范围。
重复关联	同一逻辑事实关联新增证据；检索保留代表证据与计数，审计不删原文。
冲突保留	同范围、同属性出现不同值时保留冲突；检测发生在上下文截断之前。
授权纠错	本机策略允许 maintainer 指定当前事实进行替代，保留 supersedes 关系和历史。
恢复与回放	从检查点创建独立历史分支；导出审计包、回放和状态摘要核验支持恢复。

副本预检的实际责任

prepare 固定一次提取结果，在独立副本试写，并在前后状态运行相同登录任务。报告呈现调用保持、阻断、参数变化、恢复及持续不可用；commit 核对原状态、预检指纹与风险确认后提交冻结候选。

这是一组行为信号，不等于有真值的正确率。默认自动探针只覆盖已知项目/版本的登录任务，仍由确定性规划器执行。直接 ingest 等入口仍存在；需要强制门控的宿主应收敛写入接口。

真实 AI 的作用与运行记录

本次真实模型为 Qwen/Qwen3-0.6B-GGUF 的 Q8_0 GGUF 权重，revision 为 23749fefcc72300e3a2ad315e1317431b06b590a；推理服务采用 llama.cpp b11951 的 Windows CPU 构建。权重固定，没有微调。

共享适配器保留记忆可用性门控：已知缺证、冲突或不支持的范围将 schema 约束为 clarify，模型生成澄清文本；证据充分时，模型根据自然语言任务及记忆选择调用及路径、认证字段、工具参数和引用。适配层验证协议、范围和载荷，不用规则规划器修补参数，也不访问评分规格。错误路径由模拟器判失败。缺证/冲突时的澄清决策不归因于模型独立识别。

生成设置	本次配置
温度 / 随机种子	0 / 42
输出预算 / thinking	384 tokens / 关闭
结构化响应	JSON schema：status、tool_args、evidence_ids、reason
请求与响应	216 次模型请求；216 条服务响应；7 次规划错误
token 用量	prompt 143711；completion 14676；total 158387
失败处理	单请求、无自动重试；错误单列并按任务失败保留。

每次 raw.jsonl 记录任务、上下文、完整请求、原始响应、解析结果、token 用量和模拟执行结果。网络或格式失败记录为 error；澄清只在模型明确返回 clarify 时统计。

模型调用证据与原始响应保存在本地结果包。BGE/Ollama 是既有可选接口，此报告没有将其作为本次已运行的模型。

公平比较与评分协议

本次采用 6 条 acceptance 任务流，每条 4 个检查点、每检查点 3 个探针，三种方法共 216 次执行。开发集与验收集采用不同项目和任务 ID，但共享自编构造骨架；这些数据是开发者可见的合成样例，不是独立盲测。

方法	上下文策略
无跨任务记忆	每次只给当前任务，无历史证据；仍实际调用相同模型。
同范围最近优先	按相同项目、版本和所需属性过滤原样观察，再按最近优先截断。
MemoryGuard	相同输入事件，规则治理、重复合并、冲突前置检测、授权替代及字符检索。

三组使用相同提示词模板、生成参数和事实投影，上下文证据预算为 2048 字节、top-k=8。字节数按 canonical JSON facts 数组的 UTF-8 编码计量；task、system、schema 及 status/missing/conflicts 等治理元数据在证据预算外，各组完整提示词长度不一定相同。真实 tokenizer 用量另记。

指标	分母
可回答 / 新任务成功率	独立评分标签判可回答的任务 / 其中 category=new 的任务。
旧任务退化率	前次成功、前后可答，公开任务哈希与评分答案哈希均相同的相邻旧任务配对。
错误调用率	分别报告错误调用 / 全部执行，以及错误调用 / 实际调用。
多余澄清率	可回答任务中模型返回 clarify 的次数。
正确澄清率	不可回答任务中模型返回 clarify 的次数；error 不算澄清。

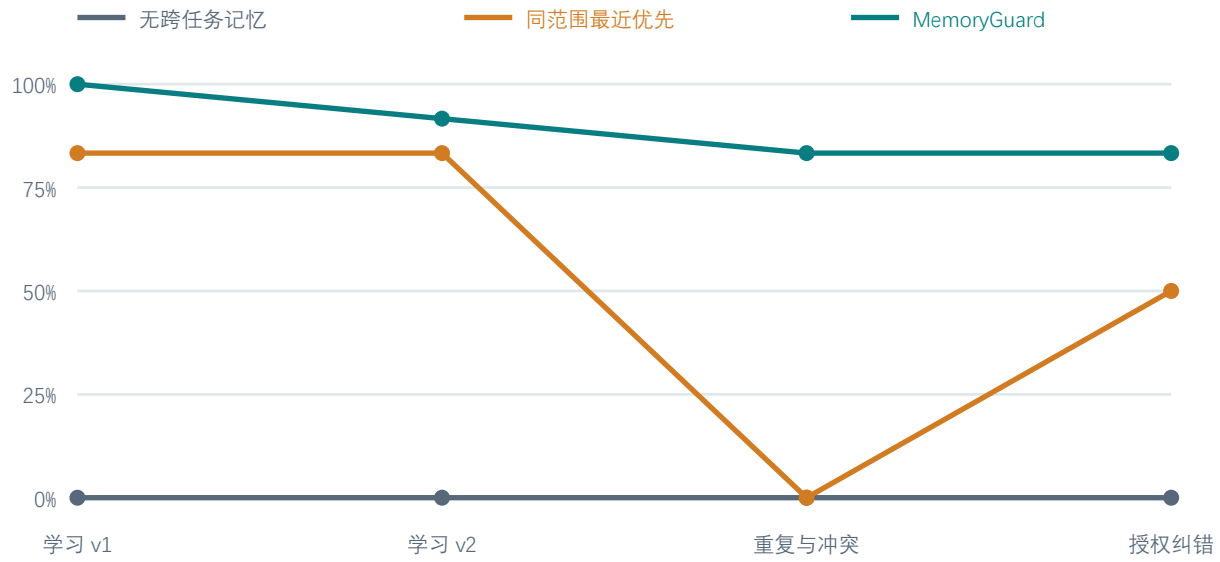
配置与输入/评分哈希在执行前保存。评分标签仅在模型返回后进入模拟器，任务输出不回写记忆。该实验比较整套记忆策略，没有单独的预检关闭消融，因此不单独归因预检收益。

本次对照结果与学习过程

方法	可回答成功	新任务成功	旧任务退化
无跨任务记忆	0/36（0.0%）	0/12（0.0%）	0/0（不适用）
同范围最近优先	21/36（58.3%）	11/12（91.7%）	5/10（50.0%）
MemoryGuard	32/36（88.9%）	10/12（83.3%）	1/17（5.9%）

方法	错误调用 / 全部	多余澄清	规划错误
无跨任务记忆	0/72（0.0%）	36/36（100.0%）	0
同范围最近优先	6/72（8.3%）	12/36（33.3%）	3
MemoryGuard	0/72（0.0%）	0/36（0.0%）	4

治理组新任务成功 10/12（83.3%），普通记忆为 11/12（91.7%），并非所有指标均改善。旧任务配对分母也因各方法先前是否成功而异，逐对记录随汇总保存。



每个检查点：可回答任务成功数 / 可回答任务数；冲突及无知识任务不计入分母。

曲线按检查点汇总可回答任务的表现，不能把同一流内多次探针当作独立用户样本。版本并存阶段的两种有记忆方法均可能成功；重复与冲突阶段才检验不同上下文策略的影响。

本次运行耗时 1325.6 秒；这些数字来自本次 config/raw/summary，不沿用 output/evaluation-v020 的历史规则规划成绩。

两个可核验案例

案例一：重复观察下仍有效的旧任务

任务：day1-acceptance-01-duplicates_and_conflict-anchor。项目 AcceptanceAPI1 / v1，检查点 13；评分答案哈希 a2ff881448ea6db9。

同范围最近优先：上下文 5 条事实、1774 字节；clarify：The required 'auth_field' is not present in the provided evidence. The 'login_path' is available, but the authentication。

MemoryGuard：上下文 2 条事实、727 字节；调用 /v1/acceptanceapi1/session，认证字段 key_1；模拟器 OK。

原样观察会为相同属性的每次出现支付上下文成本。治理方法合并逻辑事实，同时保留审计证据；本例只能支持这套记忆与上下文策略的整体比较。若两方法都失败，仍按失败报告。

案例二：保留治理方法的失败

任务：day1-acceptance-02-learn_v2-new；检查点 2，stage=learn_v2。

同范围最近优先：调用 /v2/acceptanceapi2/session，认证字段 token_2；模拟器 OK。

MemoryGuard：error：模型规划失败：ValueError: 模型引用了未提供的证据。

冲突后的合理澄清是所需行为；授权纠错要显式替代原事实，不能只把一条新笔记自动视为正确。报告保留模型本身的输出和错误，并将记忆策略效果与模型波动分开理解。

完整记录定位：结果目录 raw.jsonl，使用本页 task_id 与 method 搜索；评分文件 scoring-labels.jsonl 与输入 streams.jsonl 分开保存。

另对 3 个已保存失败案例按相同 temperature/seed 各复跑两次，共 6 次调用；状态及参数与原记录相同 6/6。复跑单独保存，不加入原实验分母，也不据此估计一般模型波动。

复现、演示与开放成果

核心软件支持 Python 3.11+，默认离线规则模式无第三方依赖。本次模型规划另外使用项目内下载的 CPU 推理运行时和权重，二者不随源码重新授权。Windows 复现步骤如下。

步骤	命令或产物
1. 核心回归	python -m unittest discover -s tests -v
2. 准备并启动模型	python -m scripts.setup_local_planner --start
3. 三组同模型比较	python -m evaluation.day1 --split acceptance --out output/evaluation-day1-rerun
4. 生成本报告	python -m scripts.build_day1_report --results output/evaluation-day1-rerun
5. 启动工作台	powershell -File start.ps1 -Port 8765
6. 学习门控示例	python -m examples.lifelong_agent

结果输出目录必须不存在，避免覆盖历史。固定模型、运行时、生成参数和数据哈希见 config、模型 manifest 与运行时 manifest。CPU 性能和模型运行库可能影响耗时及输出，复现应保留新的原始记录。

演示次序

先展示 v1 与 v2 合法并存，再对仍有效的 v1 任务回测。加入重复记录或冲突后，查看上下文、行为变化和原文证据。经过授权纠错恢复，再从历史检查点建立新分支，证明原始历史仍可追溯。

真实模型演示使用 CLI/SDK 与本次 raw.jsonl；工作台预检与恢复展示现有确定性流程。两部分在视频中分别标注，避免把预检行为信号说成模型正确率。

可复用成果包括核心源码、规则与模型适配入口、公开合成输入及独立评分标签、评测命令、原始运行记录、技术报告与操作说明。外部成果链接和上传状态需在提交前另行核实。

第三方资源与 AI 辅助披露

资源	来源 / 版本 / 许可	使用方式
Python / SQLite	本次 Python 3.12.14 / SQLite 3.53.1；沿用上游许可	存储、CLI、HTTP 及评测。
Qwen3-0.6B Q8_0	Qwen 官方 GGUF；固定 revision；Apache-2.0	CPU 生成结构化工具计划；不训练、不修改权重。
llama.cpp	ggml-org b11951；MIT	本机 CPU 推理服务；单独下载运行时。
ReportLab / Poppler	ReportLab 4.4.9；本地材料工具；沿用各自许可	报告排版与渲染核验，不是产品运行依赖。
合成数据	本工程自编；随项目 MIT	虚构 API 场景，不含真实用户或私有文档。
BGE / Ollama	既有可选接入；未计本次模型效果	许可按具体模型与接口分别说明。

自研边界

本工程实现事件协议、范围判断、证据跨度校验、重复关联、冲突与授权替代、前缀回放、副本预检及门控、会话恢复、统一预算、模型 HTTP 适配、合成评测和结果分析。基础模型、推理引擎及第三方运行库来自上游，不声称为自研。

AI 辅助开发说明

在既有 v0.2.0 原型上，Codex 协助阅读代码、实现模型规划适配与评测流程、生成合成数据、执行检查、分析运行记录和排版材料。应用运行时的 Qwen 推理与开发过程的 AI 协助分开披露。最终用途、来源授权、个人/团队角色和提交前人工审核由实际参赛者确认；本报告不把这些待确认事项写成已完成。

模型官方来源：https://huggingface.co/Qwen/Qwen3-0.6B-GGUF/tree/23749fefcc72300e3a2ad315e1317431b06b590a

推理引擎官方来源：https://github.com/ggml-org/llama.cpp/releases/tag/b11951

适用边界与提交核对

本次证据支持的结论

在 6 条开发者可见合成流和相同模型参数下，MemoryGuard 可回答成功为 32/36（88.9%），同范围最近优先为 21/36（58.3%）。旧任务退化分别为 1/17（5.9%） 与 5/10（50.0%）。这是整套记忆治理与上下文组织的局部工程验证。

尚不能由本次结果推出的结论

该样本规模和单一 API 类型不能代表通用 Agent、真实业务 API 或真人使用效果；没有独立盲标、多模型对比或预检模块消融。固定小模型可能出现格式与参数错误。默认预检只覆盖固定登录探针，存在直接写入路径。本机 maintainer 来源标签不等于多用户身份认证。

提交前还需核实

事项	当前口径
报名、缴费、团队与成果授权	本地代码和实验记录无法证明，需参赛者核实。
报告与简介	本报告及提交说明由本次结果生成；不含学校、LOGO 或指导教师信息。
视频	按独立视频产物与脚本核对，真实模型与确定性工作台需分别标明。
成果链接	正式发布位置与评审期可访问性需提交前验证。
最终上传	本报告生成不代表比赛平台提交成功。

证据索引

协议：day1-same-planner-v1；配置哈希：b5d08daf4ff97d666ded5d3ab24c318e9c354317daf77bcf5af796e3b0625915。

输入哈希：2527644c0026841d77eb91189ec439da0bfc676d18f8a26d50c50dc7018523c5；评分哈希：3af345d9b9aa2cfc4c654d35137b6d23b540e9cf55a8073875f6670cabb63329。

材料依据：仓库 HANDOFF.md、evaluation/configs/day1.md、memory_guard/{agent,llm,impact,store}.py、evaluation/day1.py 及本次结果目录。赛事格式与截止时间以提交时官方通知和比赛平台为准。